DEEP LEARNING
APRENDIZADO PROFUNDO

Prof. André Backes | @progdescomplicada

Aprendizado de Máquina

- Como programar um computador para resolver problemas muito complexos?
  - Tarefa difícil e que depende do problema a ser resolvido
- Aprendizado de Máquina
  - Estuda como dar aos computadores a capacidade de aprender a partir dos dados

Aprendizado de Máquina

- Tarefa simples de se resolver
  - Reconhecer um objeto tridimensional

- Tarefa difícil de se resolver
  - Reconhecer um objeto tridimensional mudando o ponto de vista ou as condições de iluminação

Motivação

- Apesar das melhorias recentes, os algoritmos de aprendizagem tem dificuldades para:
  - Entender cenas e descrevê-las em linguagem natural
  - Inferir conceitos semânticos suficientes a ponto de interagir com humanos

Motivação

- Como extrair informações de imagens?
  - Tradicionalmente, processamos seus pixels de modo a obter representações mais abstratas
    - Presença de bordas
    - Presença de objetos com determinadas formas
    - etc
  - Alta variabilidade de tipos de estruturas presentes

Motivação

- Como extrair informações de imagens?
  - Geralmente as imagens demandam uma combinação de estratégias
    - Cor dos gatos
    - Textura do camaleão
    - Etc

(a) (b)

(c) (d)

Deep Learning

- Ou *Aprendizado Profundo*
- É uma sub área do aprendizado de máquina
  - Utiliza algoritmos de aprendizado que extraem significado dos dados usando uma hierarquia de múltiplas camadas que imitam as redes neurais do nosso cérebro

- Busca aprender representações de dados
  - Eficácia excepcional em padrões de aprendizagem

Deep Learning

- As camadas não são projetadas por engenheiros humanos
  - As camadas são aprendidas a partir dos dados
  - Utiliza um procedimento de aprendizado para fins gerais

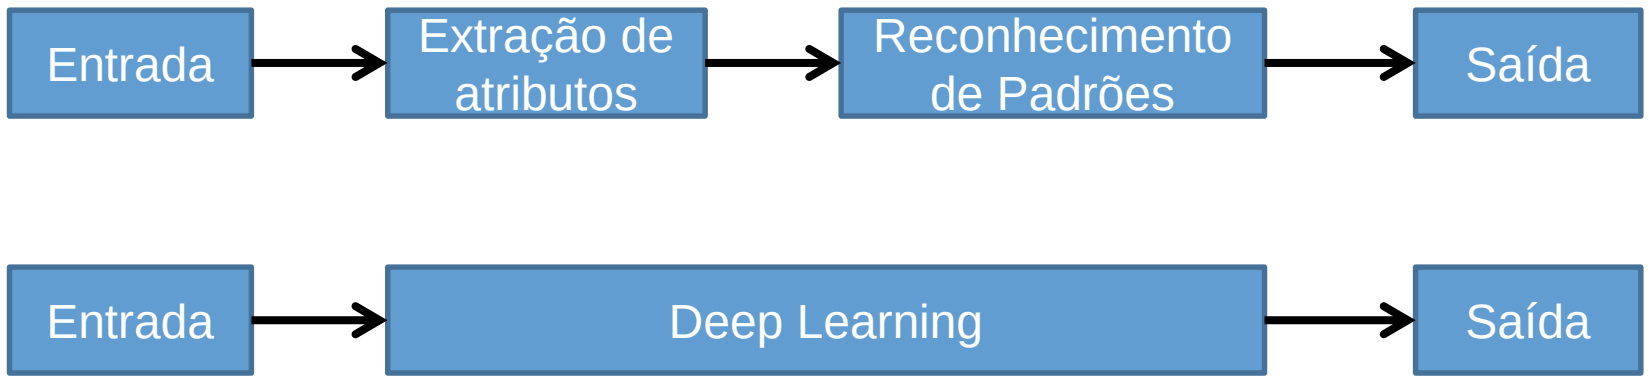

Deep Learning

- É inspirado na forma como o cérebro funciona
  - Muitos neurônios conectados
  - A força das conexões representa um conhecimento de longo prazo
- É indicado para tarefas cujo espaço de entrada seja localmente estruturado
  - Estrutura espacial ou temporal
  - Imagens, linguagem etc.

Deep Learning

- Neurônios organizados em camadas hierárquicas
  - Cada camada transforma os dados de entrada em representações cada vez mais abstratas
    - Atributos de baixo nível até conceitos mais abstratos
    - Exemplo: borda -> nariz -> face
  - A camada de saída combina esses recursos para fazer previsões

Deep Learning

- O cérebro humano funciona dessa forma
  - Primeira hierarquia (dados do córtex visual)
    - sensibilidade às bordas
  - Regiões mais abaixo são sensíveis às estruturas mais complexas
    - Exemplo: rostos

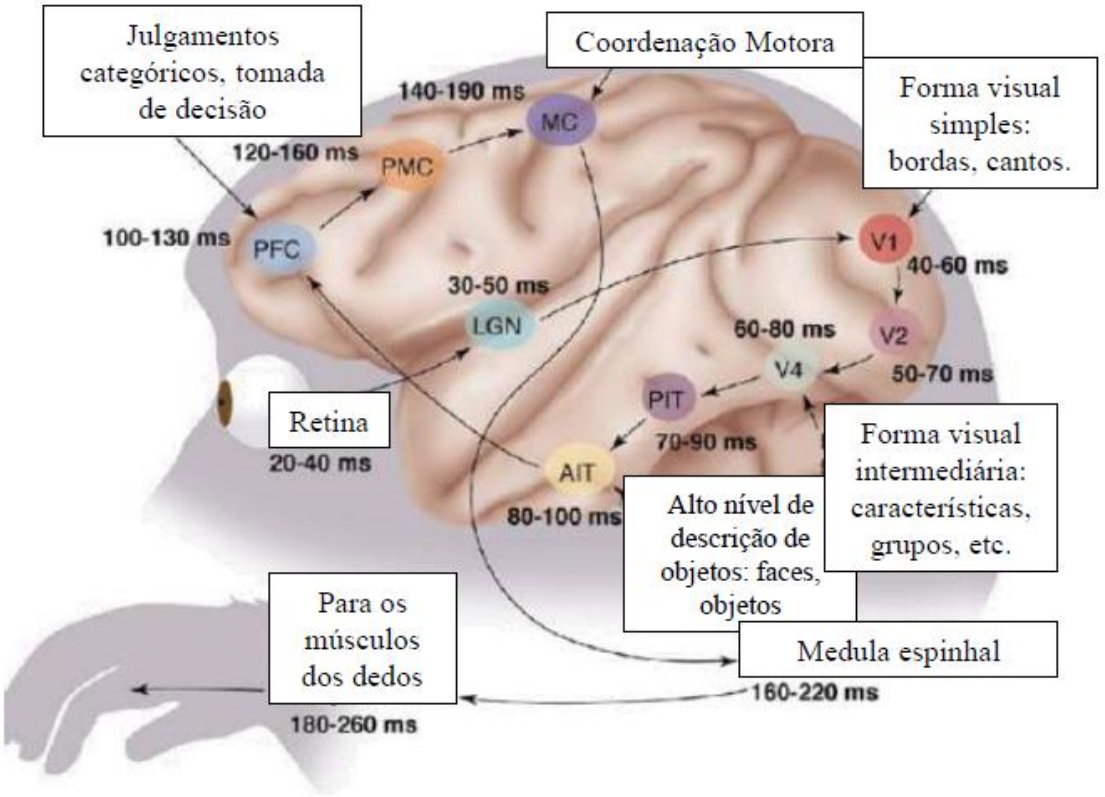

Deep Learning

- Processo de aprendizagem que descobre múltiplos níveis de abstração
  - Representações mais abstratas permitem extrair informações mais úteis para os classificadores
  - A profundidade está associada ao número de operações não lineares aprendidas

Deep Learning

- Podemos usar uma rede MLP tendo como entrada uma imagem?
  - Tamanho da entrada em geral é muito grande!
  - Uma imagem de 200 x 200: 40000 unidades de entrada
  - Considerando as várias camadas ocultas, pode-se chegar a bilhões de parâmetros a serem ajustados

Deep Learning

- Podemos usar uma rede MLP tendo como entrada uma imagem?
  - Redes são iniciadas com pesos aleatórios. Geralmente ficavam presas a mínimos locais
  - Aumento da profundidade da rede tornava difícil obter uma boa generalização

Rede Neural Convolucional

- *Convolutional Neural Network - CNN*
- Proposta por Yann LeCun e Yoshua Bengio em 1995
  - É um tipo especial de rede neural com múltiplas camadas, como a MLP
  - É inspirada na sensibilidade local e orientação seletiva do cérebro humano
  - Projetada para extrair características relevantes da entrada

Rede Neural Convolucional

- É uma rede do tipo *feed-forward*
  - Similar ao sistema visual humano, é projetada para extrair propriedades topológicas da entrada
    - Aprendem múltiplas camadas de transformações
    - As camadas são aplicadas umas sobre as outras
- Treinamento é feito utilizando o algoritmo de *back-propagation* (ou suas variações)
  - Necessitam de grandes quantidades de dados

Rede Neural Convolucional

- Um conjunto de pixels de entrada se transforma em um conjunto de votos nas classes possíveis
  - São redes capazes de reconhecer dados com muita variabilidade
    - Exemplo: caracteres escritos a mão

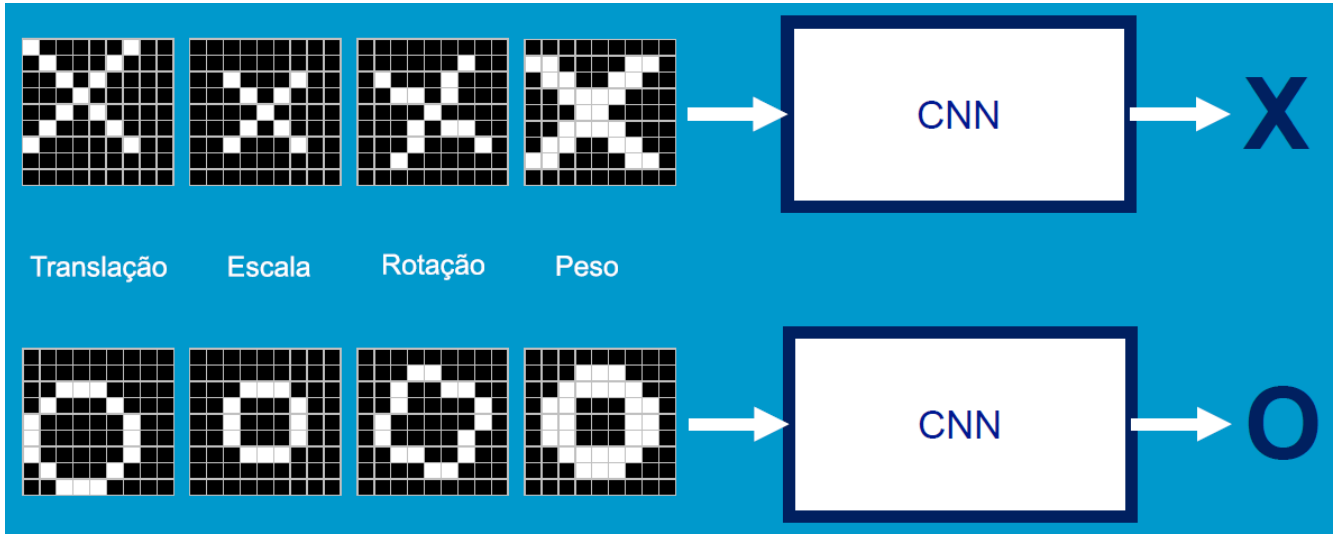

Rede Neural Convolucional

- Impacto na classificação de imagens

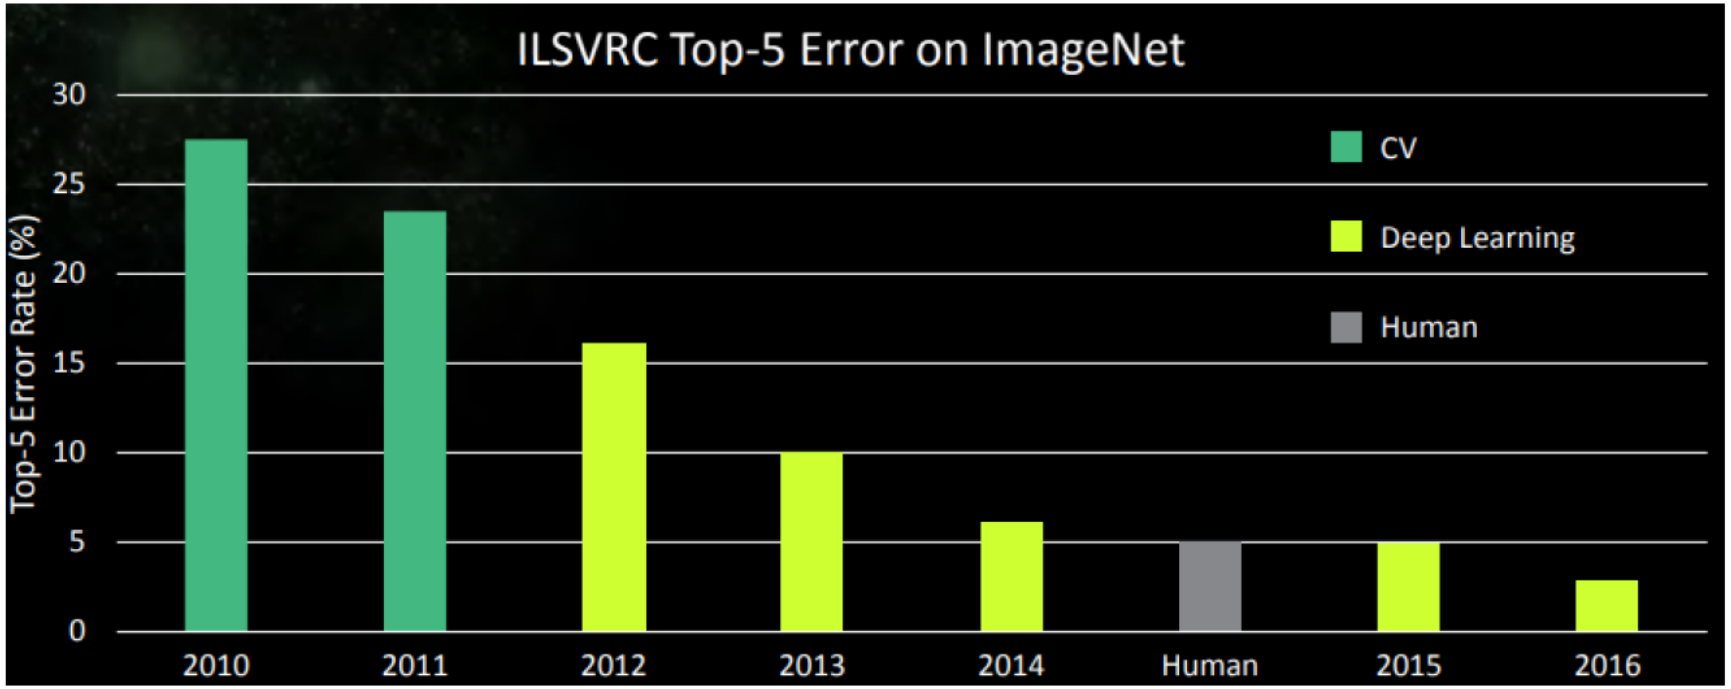

ImageNet: The "computer vision World Cup"
Fonte: https://www.dsiac.org/sites/default/files/journals/dsiac-winter-2017-volume-4-number-1.pdf

Rede Neural Convolucional

- Hubel e Wiesel, 1962
  - Estudos com o sistema visual de gatos

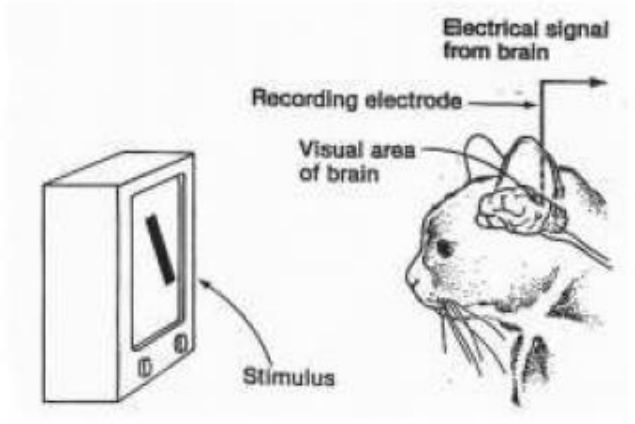

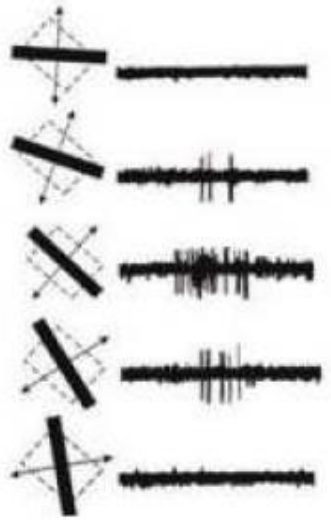

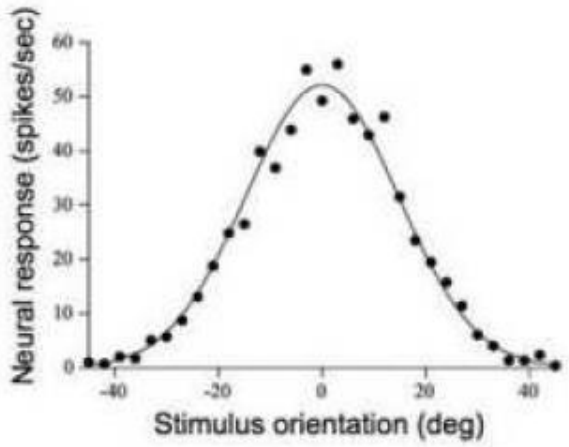

Rede Neural Convolucional

- Hubel e Wiesel, 1962
  - Estudos com o sistema visual de gatos
    - Descoberta do papel importante dos Campos Receptivos
    - Atuam como como filtros locais
      - Filtragem Espacial
    - 2 tipos de comportamentos
      - Simple Cells: Respondem a padrões de bordas na imagem;
      - Complex Cells: Possuem campos receptivos grandes e são invariantes à posição do padrão.

Rede Neural Convolucional

- Hubel e Wiesel, 1962
  - Redes convolucionais são um tipo especial de redes MLP que usam o conceito de campo receptivo local
  - Explora as correlações espaciais focando em conectividade entre unidades de processamento próximas

Filtragem Espacial

- Definição
  - Também conhecidos como operadores locais ou filtros locais
  - Combinam a intensidade de um certo número de pixels, para gerar a intensidade da imagem de saída.

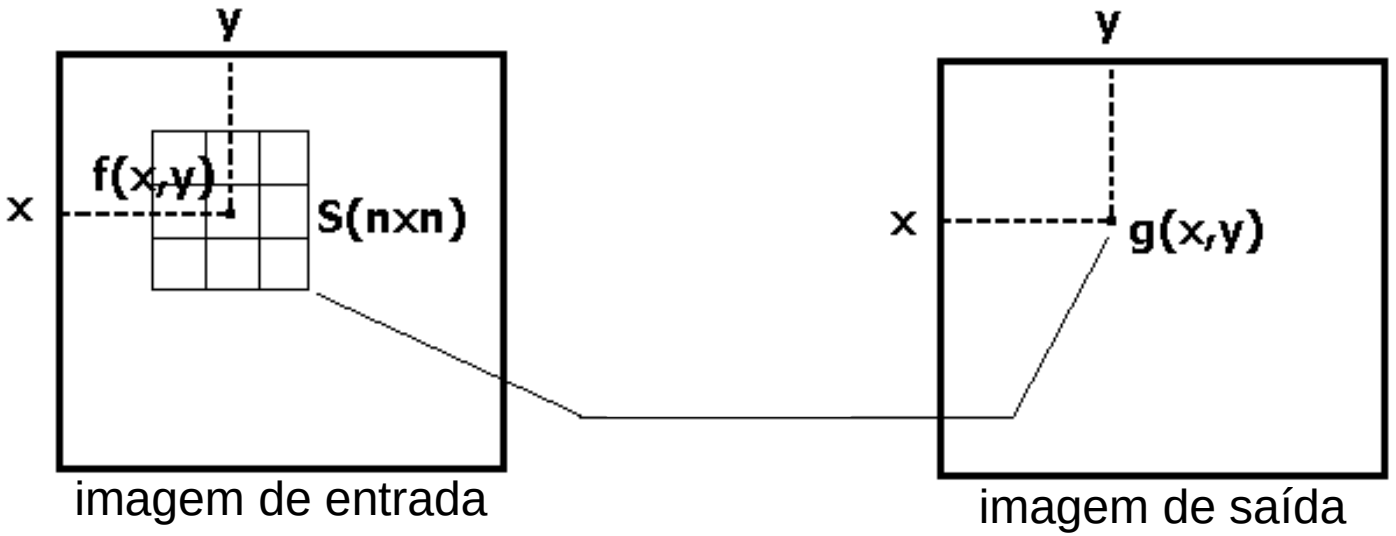

Filtragem Espacial

- São técnicas baseadas na convolução de
  - templates
    - janelas, matrizes
  - tuplas
    - conjunto de pixels

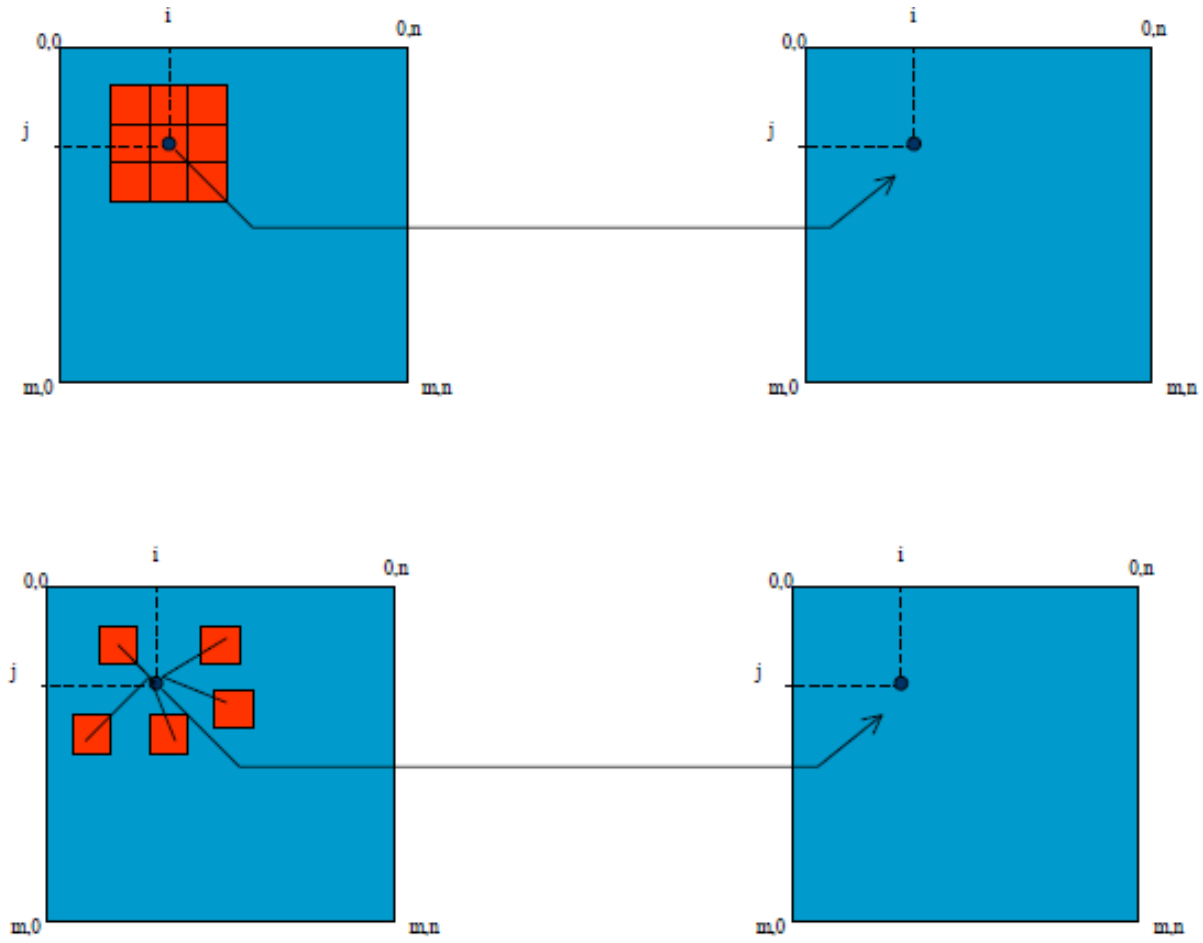

Filtragem Espacial

- Uma grande variedade de filtros digitais podem ser implementados através da convolução no domínio do espaço
  - São os operadores locais mais utilizados em processamento de imagens, com diversas aplicações
    - Pré-processamento
    - Eliminação de ruídos
    - Suavização
    - Segmentação

Filtragem Espacial

- Refere-se ao plano da imagem
  - Envolve a manipulação direta dos pixels da imagem utilizando uma máscara espacial (kernels, templates, janelas)

$$\frac{1}{9}\times\begin{bmatrix}1 & 1 & 1\\ 1 & 1 & 1\\ 1 & 1 & 1\end{bmatrix} \qquad \begin{bmatrix}-1 & 0 & 1\\ -2 & 0 & 2\\ -1 & 0 & 1\end{bmatrix}$$

- Valores das máscaras são chamados de coeficientes
  - O processo de filtragem é similar a um operação matemática denominada **convolução**

Filtragem Espacial

- Processo de filtragem
  - Cada elemento da máscara é multiplicado pelo valor do pixel correspondente na imagem ***f***
  - A soma desses resultados é o novo valor do nível de cinza na imagem ***g***
  - Exemplo: *w* é uma janela de *n x n* = *k* pixels. O processo de filtragem para cada pixel na imagem ***g(x,y)*** será dada por

$$g(x,y) = \sum_{i=1}^{k} w_i . f(x,y)$$

Filtragem Espacial

- Processo de filtragem
  - *(a,b,c,d,e,f,g,h,i):* são os valores dos níveis de cinza na vizinhança de *f(x,y)*
  - *(w_1 a w_9)*: são os coeficientes da máscara
  - O valor do pixel *g(x,y)* é dado por

$$g(x,y) = w_1.a + w_2.b + w_3.c + w_4.d + w_5.e + w_6.f + w_7.g + w_8.h + w_9.i$$

Imagem --- f(x,y)

	a	b	c
	d	e	f
	g	h	i

k = 3 x 3 = 9

w_1	w_2	w_3
w_4	w_5	w_6
w_7	w_8	w_9

Filtragem Espacial

- Processo de filtragem

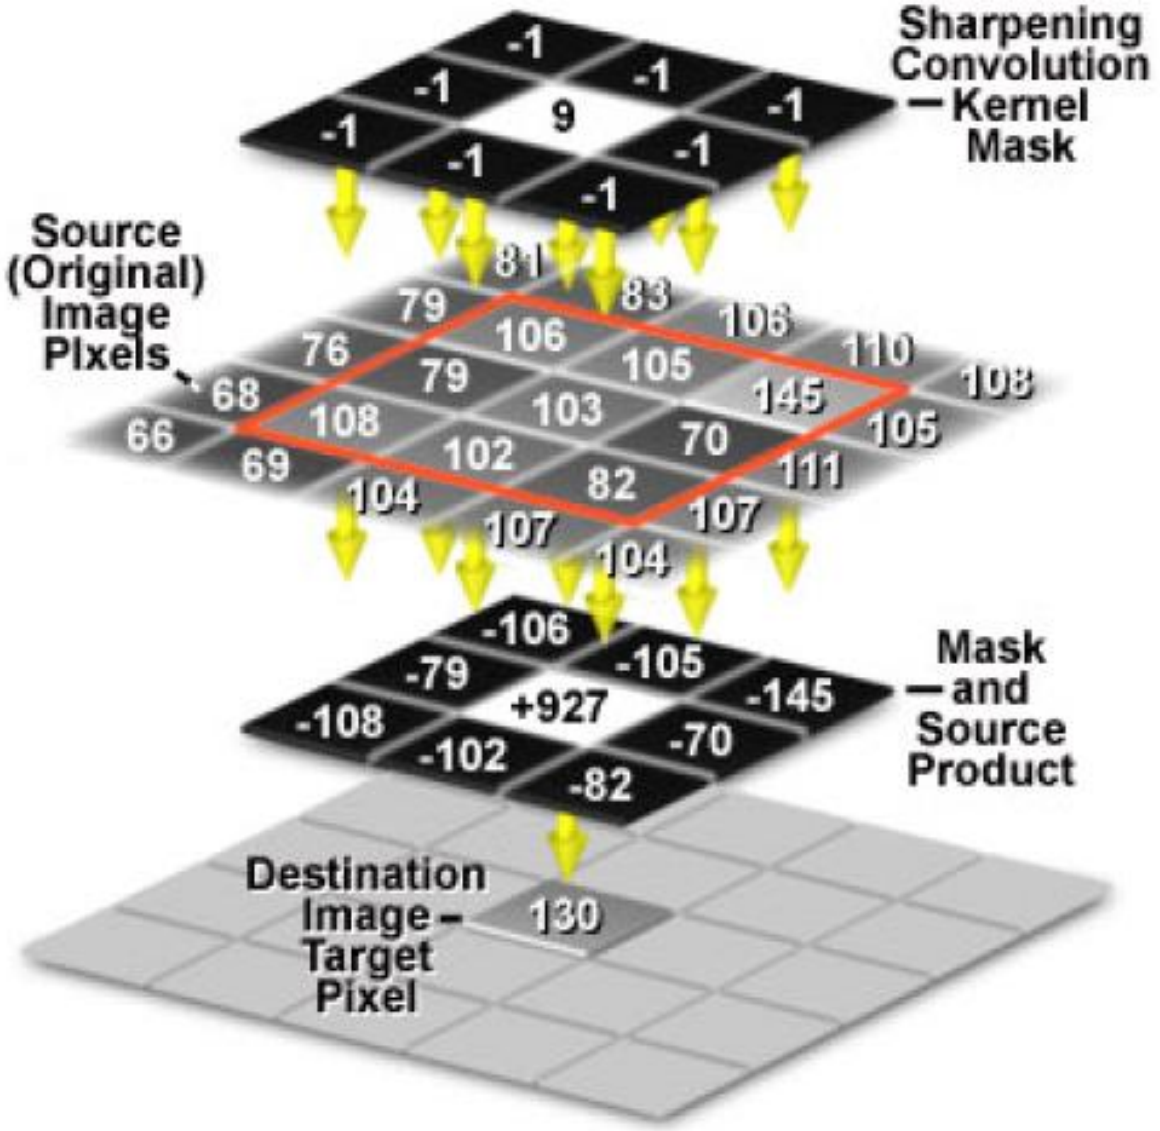

Filtragem Espacial

- A esse processo de filtragem dá-se o nome de **convolução**
  - Desloca-se a máscara (espelhada) sobre a imagem e calcula-se a soma dos produtos em cada local
    - A equação devem ser aplicada sobre todas as posições *x* e *y* da imagem

$$w(x,y) * f(x,y) = \sum_{s=-a}^{a} \sum_{t=-b}^{b} w(s,t) f(x-s, y-t)$$

$$a = (m-1)/2 \qquad b = (n-1)/2$$

Espelhamento ou rotação, feito na imagem

Exemplo de Convolução

- Conjunto de operações

Desloca, Multiplica, Soma

máscara

1	0
0	1

Imagem

1	1	3	3	4
1	1	4	4	3
2	1	3	3	3
1	1	1	4	4

Resultado

2	5	7	6	*
2	4	7	7	*
3	2	7	7	*
*	*	*	*	*

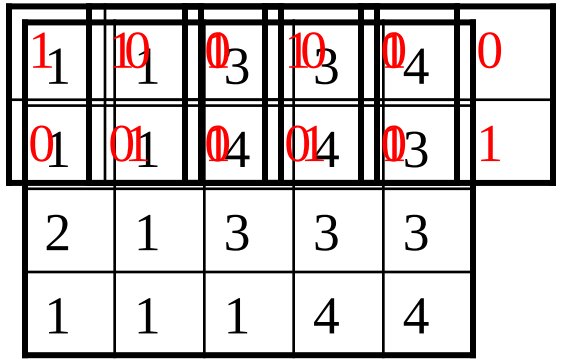

A imagem resultado é menor do que a imagem original. Os valores marcados com * não podem ser calculados.

Convolução

- Convenção
  - Nas máscaras de tamanho par (2 x 2, 4 x 4 , ...) o resultado é colocado sobre o primeiro pixel
  - Nas máscaras de tamanho ímpar (3 x 3, 5 x 5, ...) o resultado é colocado sobre o pixel central
  - A imagem resultante da convolução não necessita obrigatoriamente ser menor do que a imagem original
    - Convolução aperiódica
    - Gabarito truncado

Convolução aperiódica

- O valor 0 é atribuído aos resultados não calculáveis

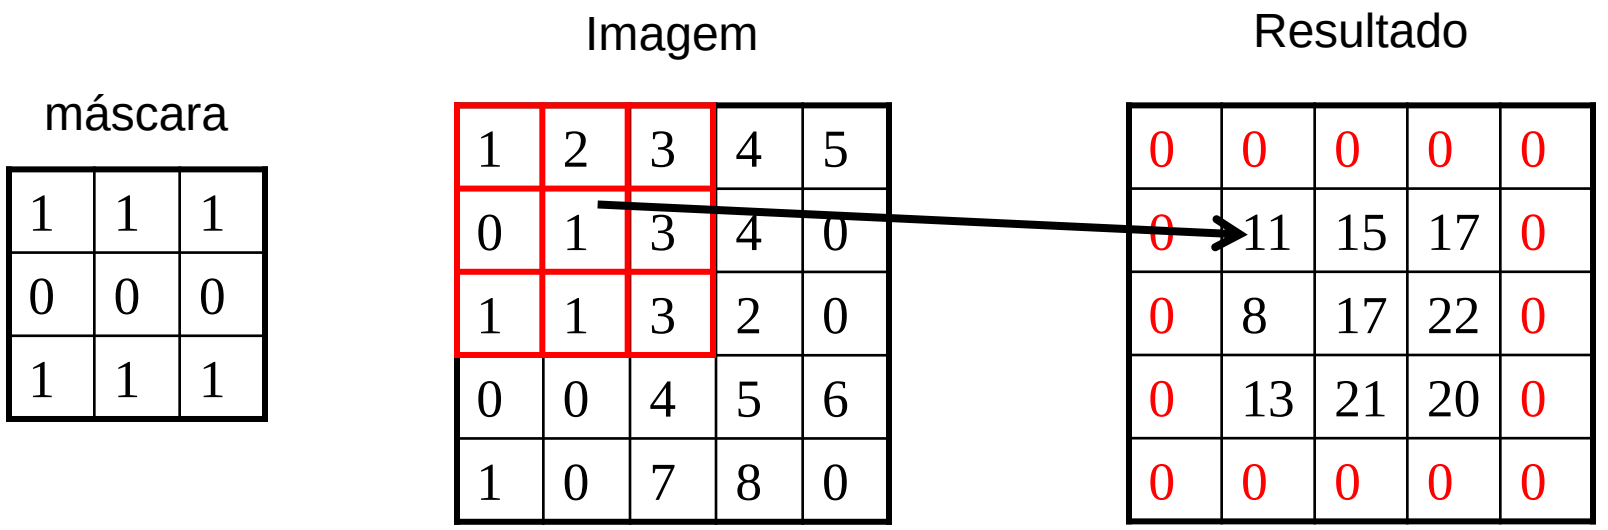

Gabarito truncado

- Centra-se a máscara com o primeiro pixel da imagem atribuindo o valor 0 aos valores inexistentes na imagem

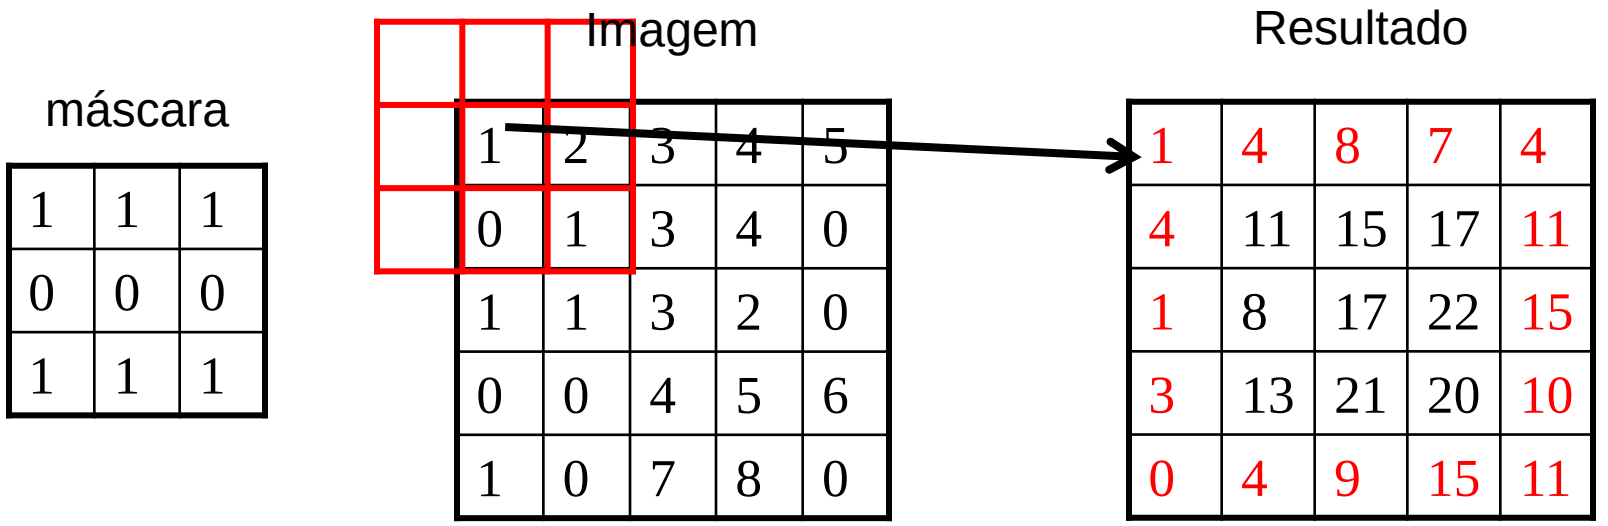

1	1	1
0	0	0
1	1	1

1	2	3	4	5
0	1	3	4	0
1	1	3	2	0
0	0	4	5	6
1	0	7	8	0

1	4	8	7	4
4	11	15	17	11
1	8	17	22	15
3	13	21	20	10
0	4	9	15	11

Custo da convolução

- O custo computacional da convolução é alto
  - Em um imagem de tamanho $M \times M$ e máscara $N \times N$, o número de multiplicações é de M^2N^2
    - Exemplo: imagem de 512 x 512 e máscara de 16 x 16 = 67.108.864 multiplicações.
- Problema “resolvido” com o uso de GPUs

Máscaras de convolução

- O tamanho da máscara e os valores de seus coeficientes definem o tipo de filtragem produzido
- Alguns exemplos
  - Filtro Passa Baixa e média espacial (suavização)
  - Filtro Passa Alta (realce)
  - Gradientes (robert, sobel, etc): detectores de borda

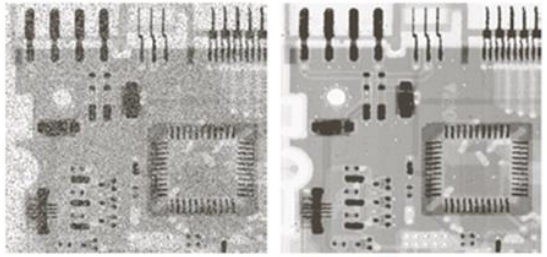

Remoção de ruído

Suavização

Realce

Detectores de Bordas

Estrutura da Rede

- Uma Rede Neural Convolucional é formada pela combinação de 4 tipos de camadas
  - Camada de Convolução
  - Camada ReLU
  - Camada de *Pooling*
  - Camada *Fully Connected*

Camada de Convolução

- Utiliza a ideia de Campos Receptivos Locais
  - A camada calcula a saída dos neurônios conectados a regiões locais da entrada
  - Trata-se de um detector de atributos
    - Aprende automaticamente a filtrar as informações não necessárias de uma entrada usando um filtro de convolução

Camada de Convolução

- Os filtros são aprendidos pelo algoritmo
  - A inicialização dos filtros é aleatória
  - O pesos dos filtros são os mesmo em qualquer uma das regiões do mapa
  - A convolução é linear
  - Facilita o paralelismo do processo

Camada de Convolução

- Uma imagem permite gerar um conjunto de imagens

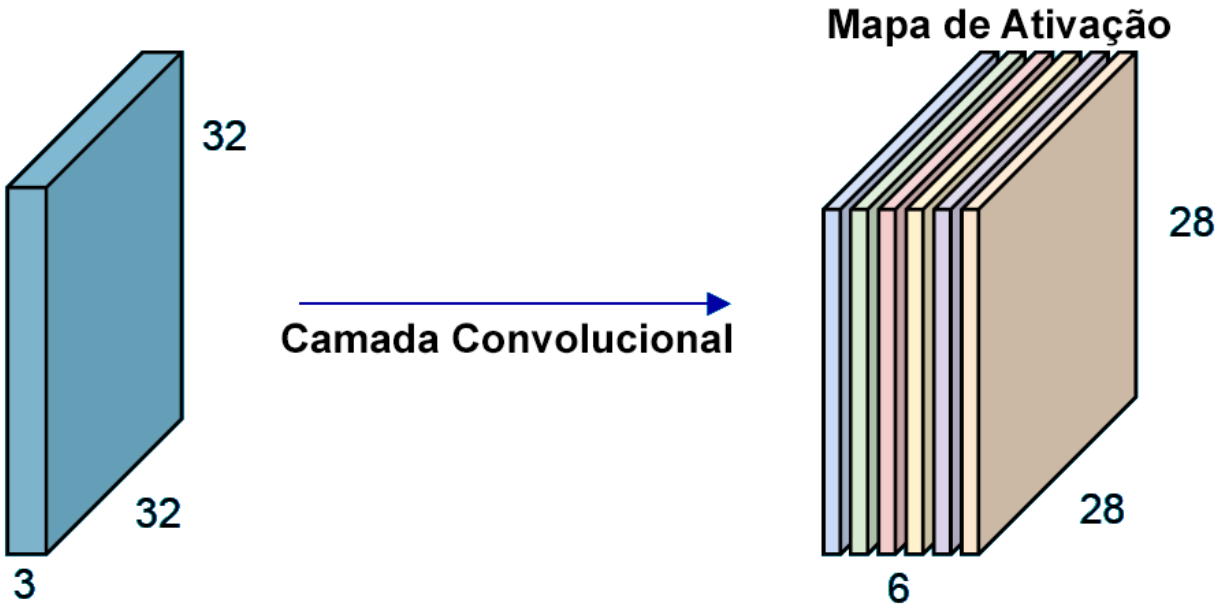

Camada de Convolução

- Permite aprender diferentes tipos de atributos em cada camada

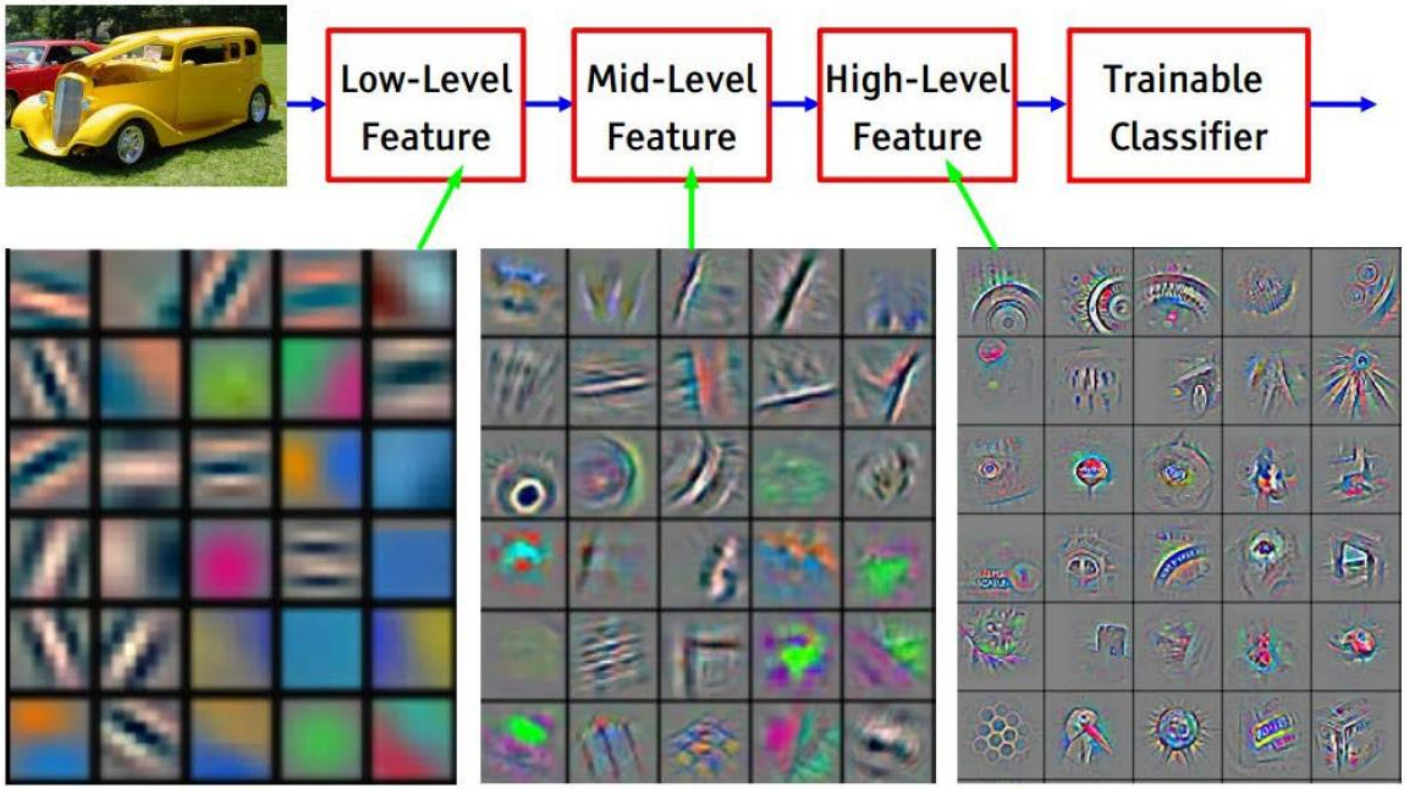

Feature visualization of convolutional net trained on ImageNet from [Zeiler & Fergus 2013]

Camada ReLU

- Do inglês, **Re**ctified **L**inear **U**nits
  - Função de ativação ponto-a-ponto
  - É a função de ativação usada nas redes convolucionais
    - Treino mais muito rápido
    - Mais expressiva que a função logística
  - Evita o problema do gradiente de fuga

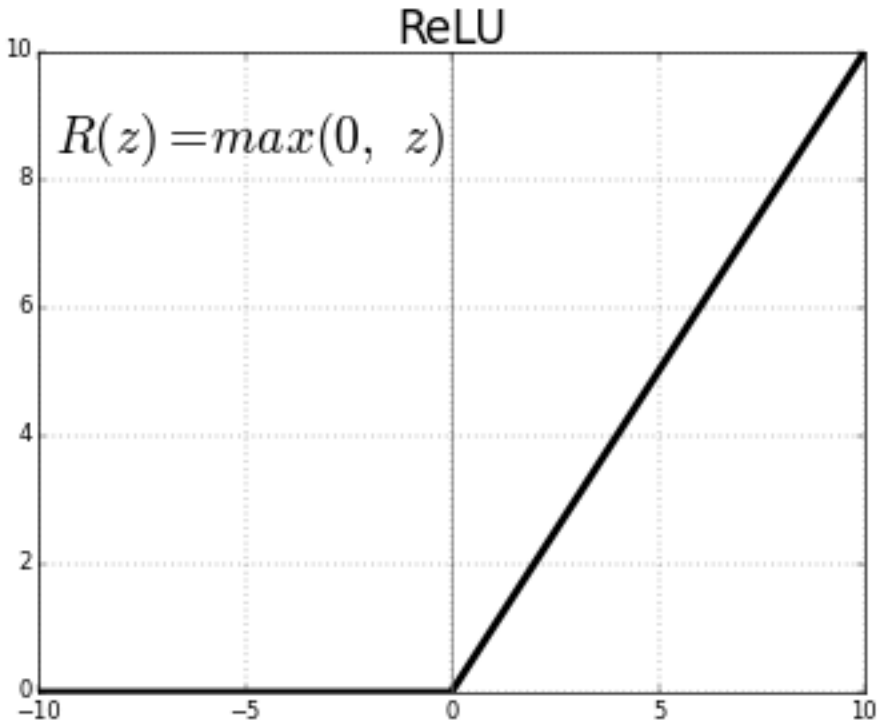

Camada ReLU

- Gradiente de Fuga ou Dissipação do Gradiente
  - O gradiente em redes neurais profundas é instável
    - Com isso, ele tende a explodir ou a desaparecer nas camadas anteriores
  - Atualização dos pesos da rede é proporcional à derivada parcial da função de erro com respeito ao peso em cada iteração
    - Gradiente extremamente pequeno impede o peso de ser alterado

Camada ReLU

- Exemplo de aplicação nos dados

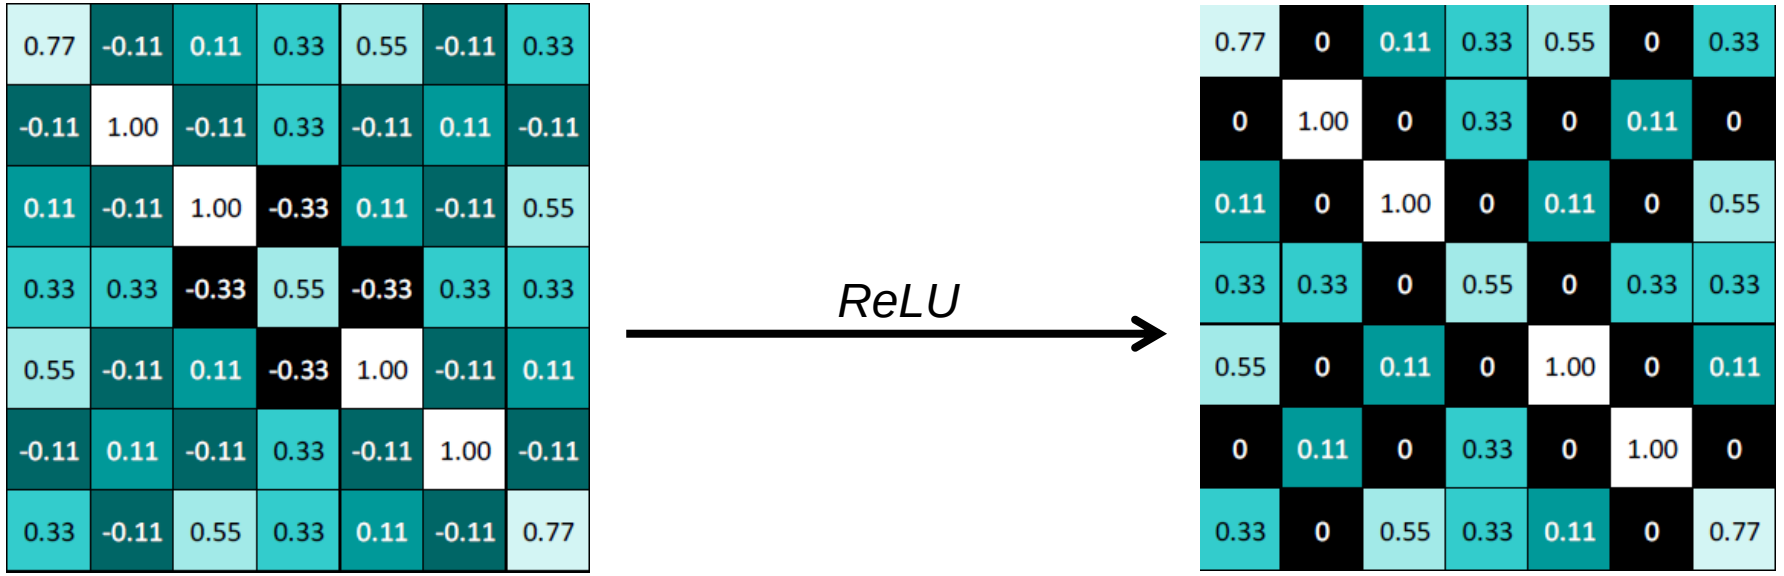

Camada ReLU

- Exemplo de aplicação em uma “imagem”

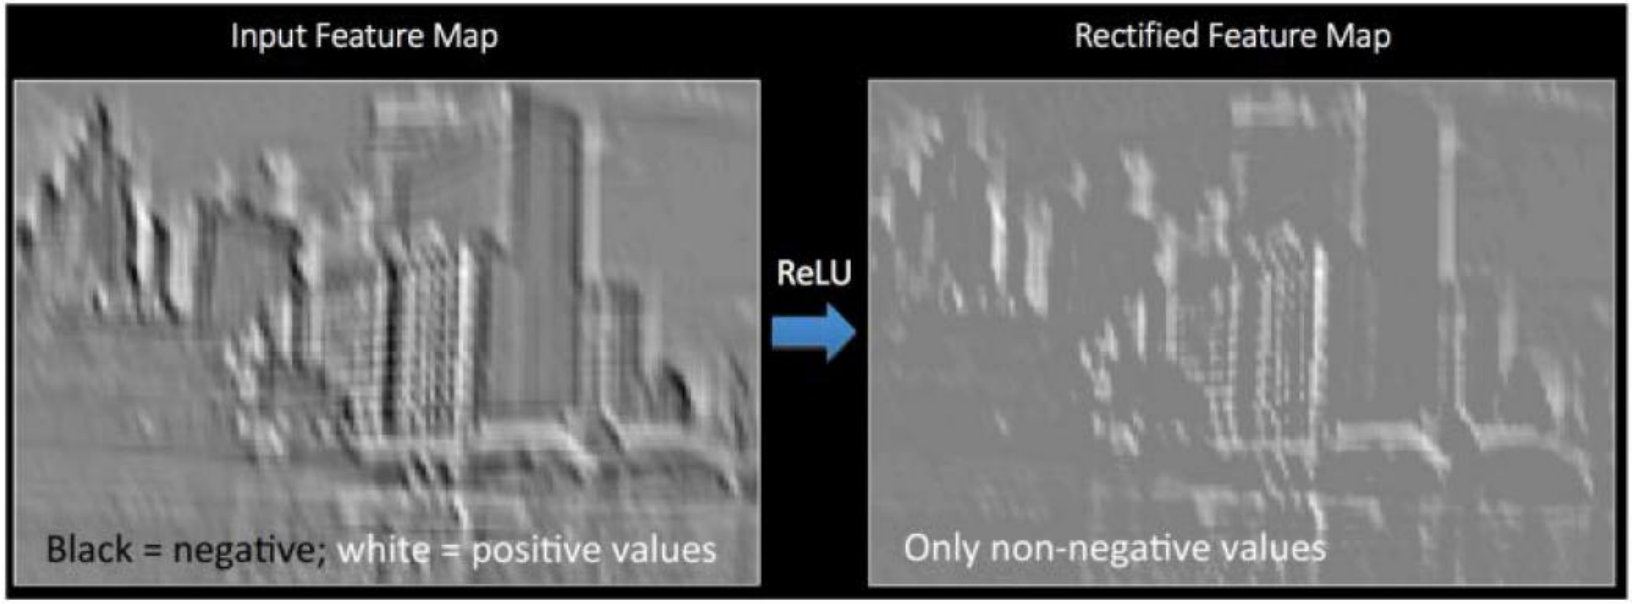

Camada de *Pooling*

- Também chamada de *downsample*
  - Reduz o tamanho das imagens de entrada
  - Reduz a sensibilidade a deslocamentos e outras formas de distorção
    - Torna a convolução invariante a translação, rotação e *shifting* (janelamento)
  - Ajuda a detectar objetos em alguns locais incomuns e reduz o tamanho da memória

Camada de *Pooling*

- Existem vários tipos de *pooling*
  - Min
  - Max
  - Média
- Mais utilizado: *max-pooling*
  - Seleciona-se a **maior** ativação para propagar na região de interesse
  - Permite capturar semelhanças em imagens mesmo que elas estejam um pouco deslocadas

Camada de *Pooling*

- Algoritmo *max-pooling*
  - Selecione o tamanho da janela e o passo (*stride*)
    - 2 x 2, com passo 2
    - 3 x 3, com passo 3
  - Deslize sua janela sobre a imagem
  - Para cada janela, selecione o maior valor

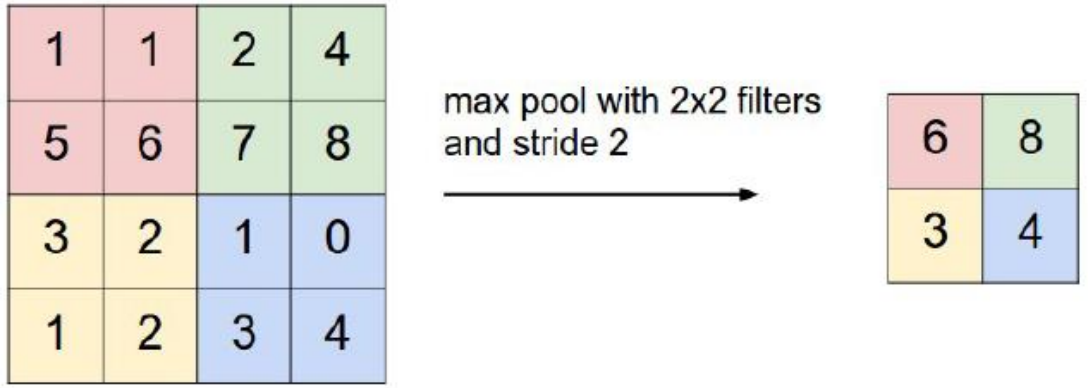

Camada de *Pooling*

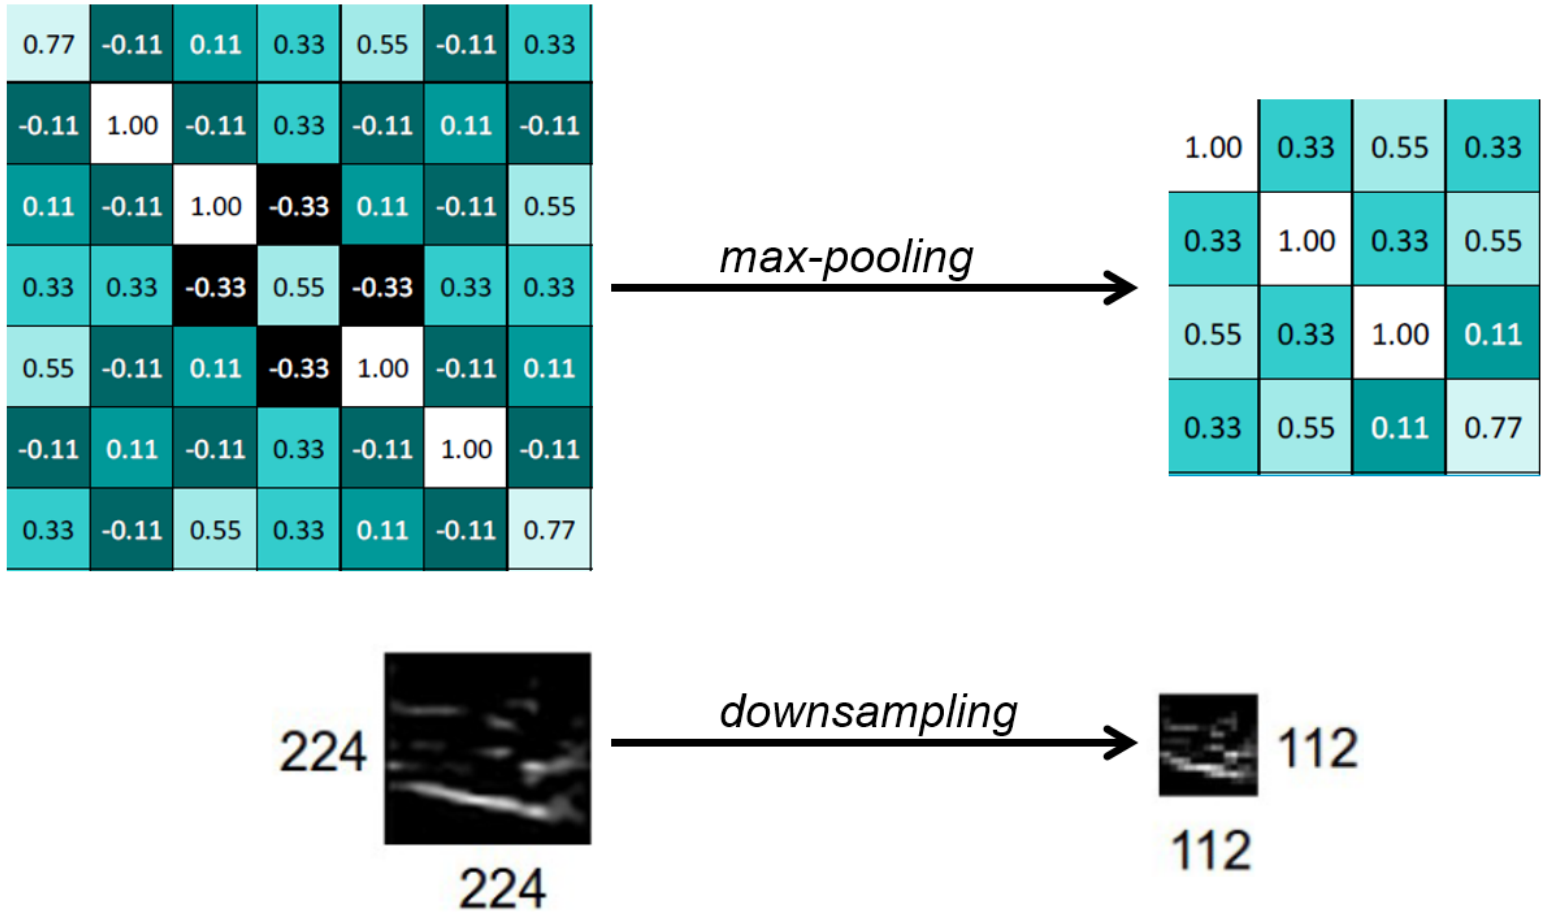

Camada Fully Connected

- Também chamada de camada *Dense*
  - Trabalha como uma *Rede Multilayer Perceptron*
    - Os neurônios atuam sobre todos os dados fornecidos pelas camadas anteriores
    - Cada neurônio da camada de saída representa uma classe do problema

Camada Fully Connected

- Camada Convolucional
  - Extração de atributos de alto nível da imagem

- Camada Fully Connected
  - Busca aprender como classificar esses atributos em um conjunto de classes

Camada Fully Connected

- Função softmax
  - Utilizada quando a rede é voltada para tarefas de classificação
  - Permite interpretar os valores da camada de saída como uma distribuição de probabilidades

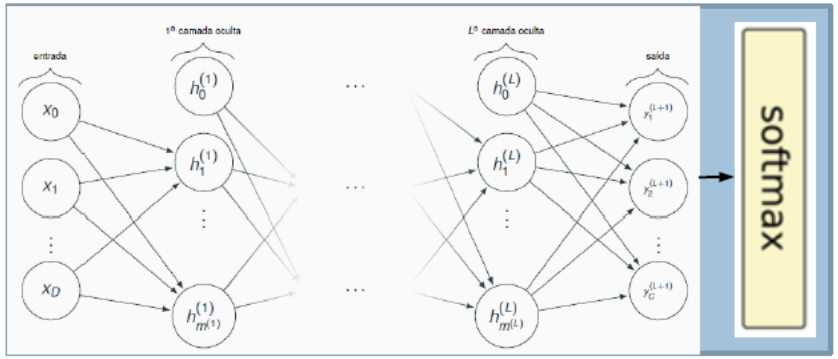

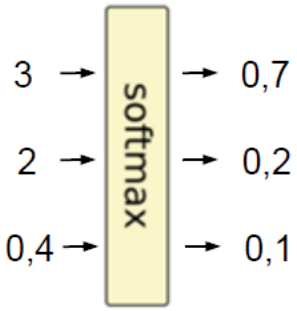

Treinamento

- *Error back-propagation* ou Retropropagação do erro
- Funcionamento
  - Saída produzida pela rede é diferente do resultado esperado
  - Determina o grau de responsabilidade de cada parâmetro da rede
  - Valor do parâmetro é alterado com o propósito de reduzir o erro produzido

Treinamento

- *Error back-propagation* ou Retropropagação do erro
  - Sentido direto (*forward*)
    - Cálculo da saída e do erro
  - Sentido inverso (*backward*)
    - Propagação do erro
    - Erro = (resposta obtida) – (resposta correta)

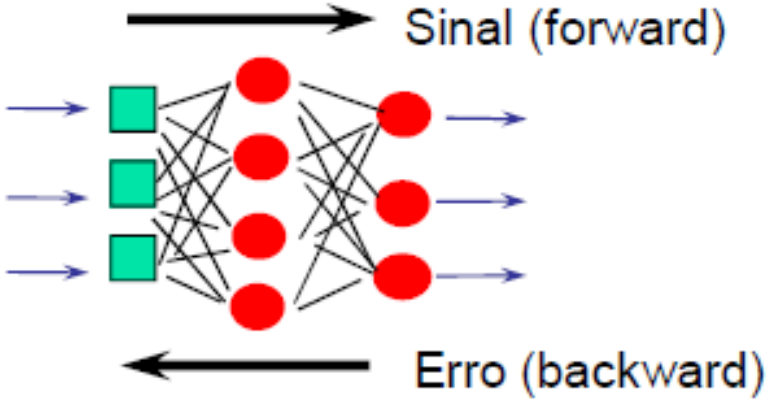

Treinamento

- *Error back-propagation* ou Retropropagação do erro
  - Utiliza a regra da cadeia para calcular o quão rápido o erro muda quando mudamos a ativação de uma unidade oculta
  - Pesos são ajustados para que as previsões fiquem mais precisas

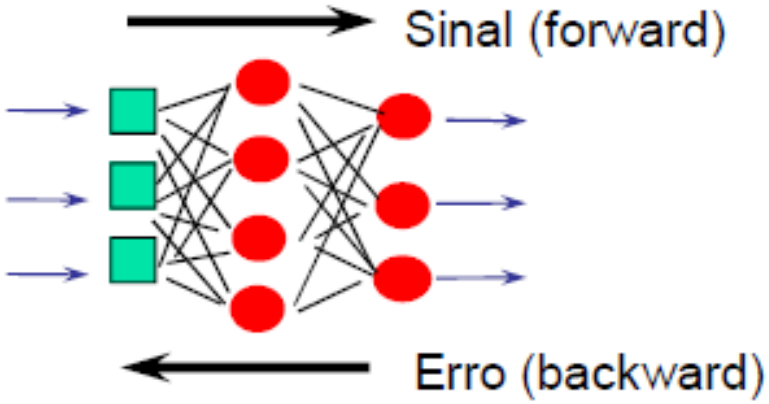

Dropout

- Desligamento de neurônios
  - Consiste em eliminar aleatoriamente (e temporariamente) alguns dos neurônios ocultos na rede
  - Os neurônios de entrada e saída não são afetados
  - Permite aprender descritores mais robustos dos dados

Dropout

- Desligamento de neurônios

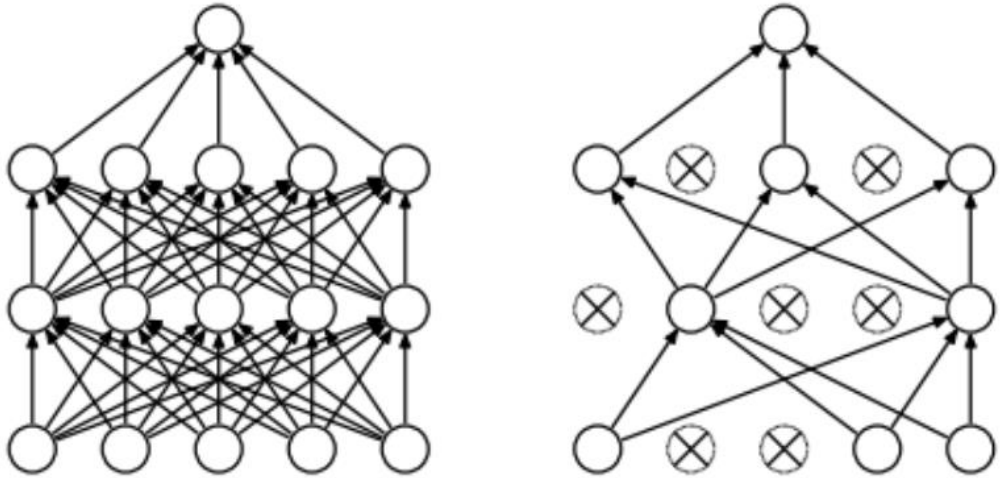

(a) Standard Neural Net (b) After applying dropout.

Figure 1: Dropout Neural Net Model. **Left**: A standard neural net with 2 hidden layers. **Right**: An example of a thinned net produced by applying dropout to the network on the left. Crossed units have been dropped.

Dropout - A Simple Way to Prevent Neural Networks from Overfitting (JMLR, 2014)

Dropout

- Desligamento de neurônios = rede mais robusta
  - Eliminar neurônio equivale a treinar redes neurais diferentes
    - Diminui o *overfitting*
  - Reduz co-adaptações complexas de neurônios
    - Um neurônio não pode confiar na presença de outros neurônios em particular, pois podem estar desligados
    - O neurônio é forçado a aprenda atributos mais robustos e úteis em conjunto com outros neurônios aleatoriamente selecionados

Batch Normalization

- Normalização em Lote
- Durante o treinamento, os dados são normalizados
  - No entanto, os dados são transformados a medida que passam pelas diferentes camadas da rede
  - Isso pode fazer com que os dados voltem a ficar desnormalizados

Batch Normalization

- Esse problema é conhecido como **mudança de covariável interna** (*internal covariate shift*)
  - Aumenta o tempo necessário para treinar a rede
  - Aumenta as chances de dissipação do gradiente
  - Se torna pior a medida que a rede fica mais profunda

Batch Normalization

- Consiste em normalizar os dados fornecidos a cada camada oculta
- Vantagens
  - Reduz a dependência da inicialização
  - Melhora o fluxo de gradiente em redes profundas
  - Diminui o tempo de treinamento
    - Diminuição de 14 vezes na quantidade de épocas necessárias para treinar a rede

Projetando a Rede

- Como deve ser a estrutura da rede?
  - Quantas camadas?
  - Quais tipos de camadas usar?
  - Qual a ordem das camadas?
  - Qual tipo de filtro?
  - Qual tipo de normalização?
  - Taxa de Dropout?

Projetando a Rede | Exemplos

- AlexNet (Krizhevsky, 2012)
  - 60 milhões de parâmetros
    - Entrada: 224 x 224
    - conv1: 96 filtros de 11 x 11 x 3, *stride* 4
    - conv2: 256 filtros de 5 x 5 x 48
    - conv3: 384 filtros de 3 x 3 x 256
    - conv4: 384 filtros de 3 x 3 x 192
    - conv5: 256 filtros de 3 x 3 x 192
    - fc1 e fc2: 4096 neurônios

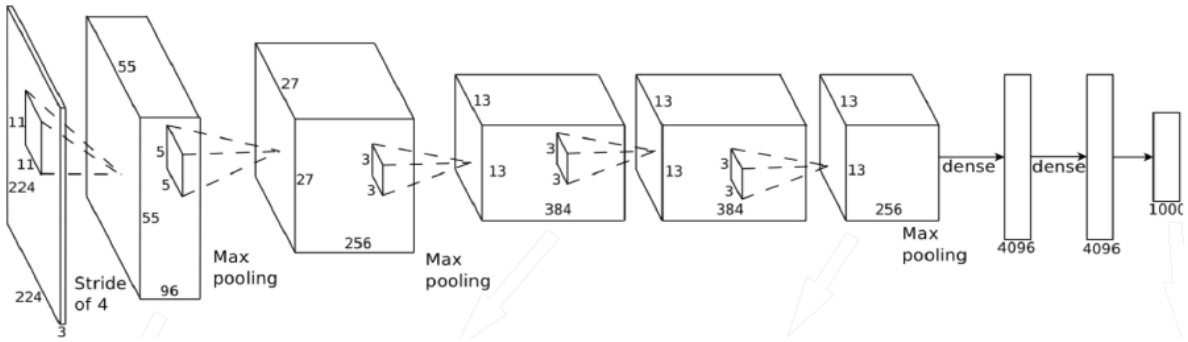

Projetando a Rede | Exemplos

- VGG 19 (Simonyan 2014)
  - +camadas, -filtros = menos parâmetros
  - Entrada: 224 x 224
  - Filtros: todos 3 x 3
  - conv 1-2: 64 filtros + maxpool
  - conv 3-4: 128 filtros + maxpool
  - conv 5-6-7-8: 256 filtros + maxpool
  - conv 9-10-11-12: 512 filtros + maxpool
  - conv 13-14-15-16: 512 filtros + maxpool
  - fc1 fc2: 4096 neurônios

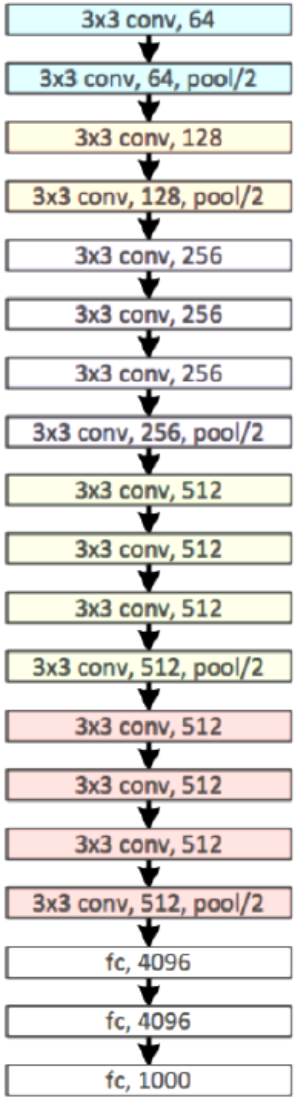

Projetando a Rede | Exemplos

- GoogLeNet (Szegedy, 2014)
  - 22 camadas
  - Inicia com 2 camadas convolucionais
  - Camada Inception (“filter bank”)
    - Filtros 1 x 1, 3 x 3, 5 x 5 + max pooling 3 x 3
    - Reduz a dimensionalidade usando filtros 1 x 1
    - 3 classificadores em diferentes partes

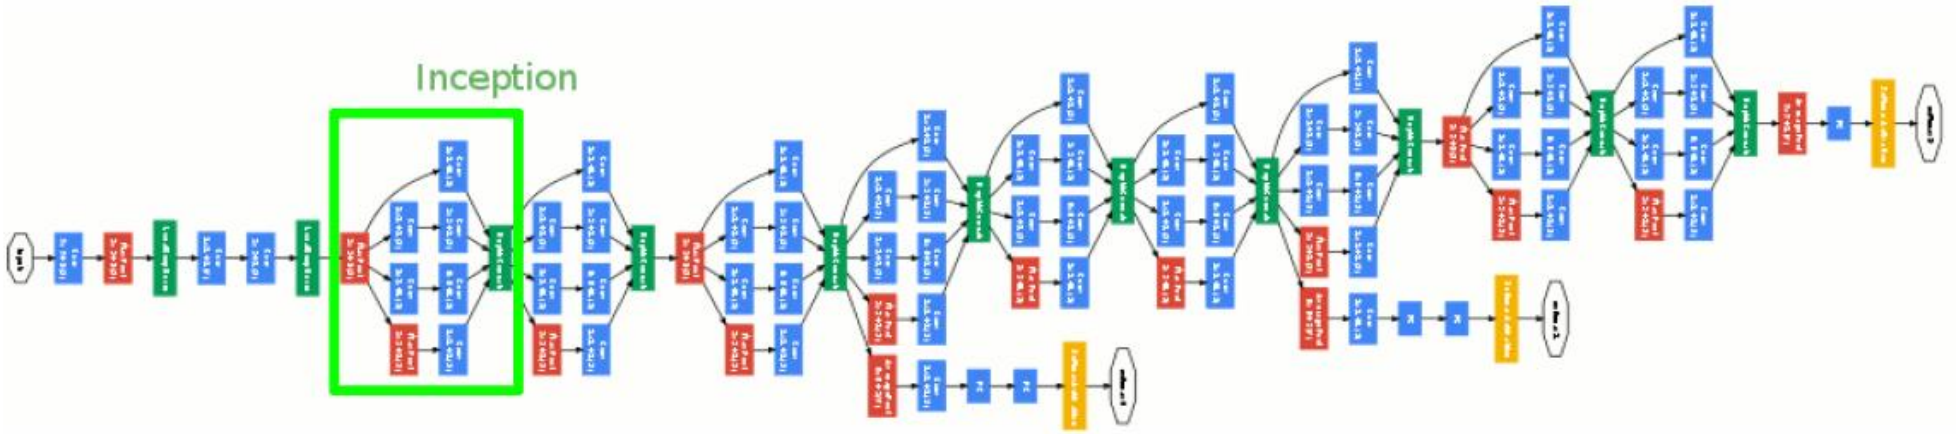

Projetando a Rede

- Residual Network - ResNet (He et al, 2015)
  - -filtros, +camadas (34-1000)
  - Arquitetura residual
    - Adicionar mais camadas não melhora o desempenho
      - Dificuldade de treinar
      - Dissipação do Gradiente
    - *Skip Connection:* adiciona a entrada original a saída de um bloco de convolução

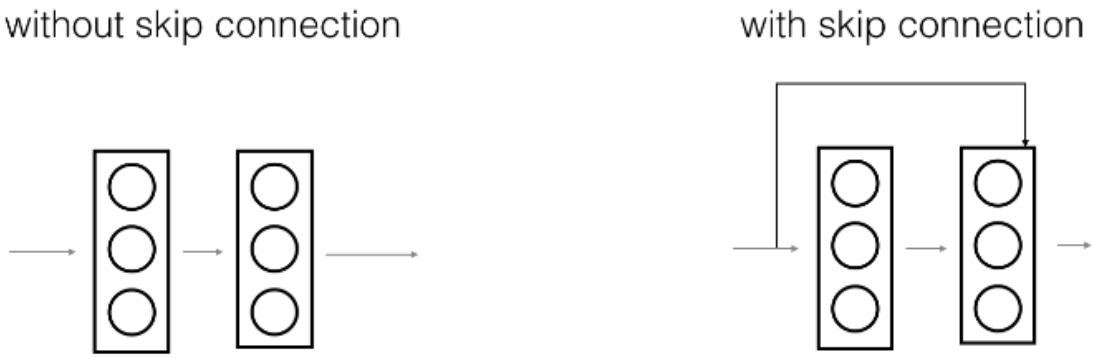

Projetando a Rede

- Residual Network - ResNet (He et al, 2015)
  - O modelo aprende uma função identidade de modo que as camadas mais altas nunca terão um desempenho inferior as camadas mais baixas

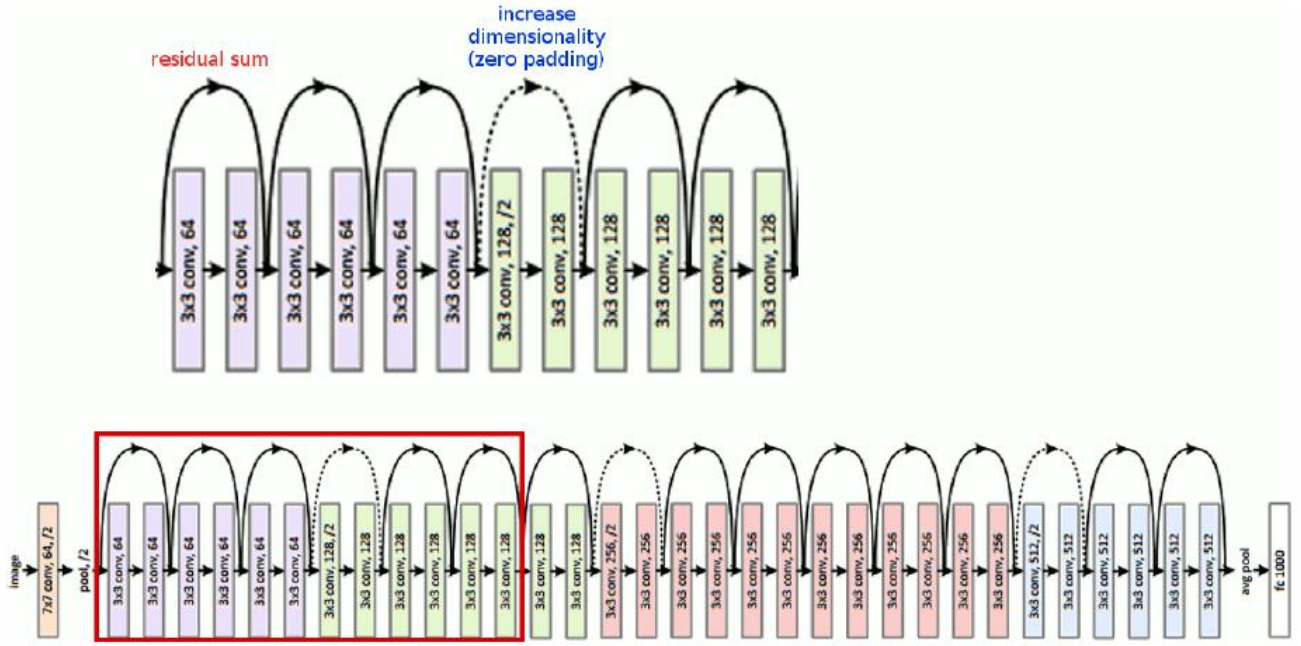

Utilizando uma rede pré-treinada

- Finetuning
  - Dados similares a ImageNet
    - Manter o treinamento das camadas convolucionais
    - Treinar apenas as camadas FC

Utilizando uma rede pré-treinada

- Finetuning
  - Dados diferentes da ImageNet
    - Manter o treinamento das camadas convolucionais inferiores
    - Treinar as outras camadas convolucionais e as camadas FC

Utilizando uma rede pré-treinada

- Extração de atributos
  - Pegar os valores de ativação das últimas camadas de convolução ou FC
    - Utilizar um classificador externo: SVM, k-NN, Naive Bayes etc

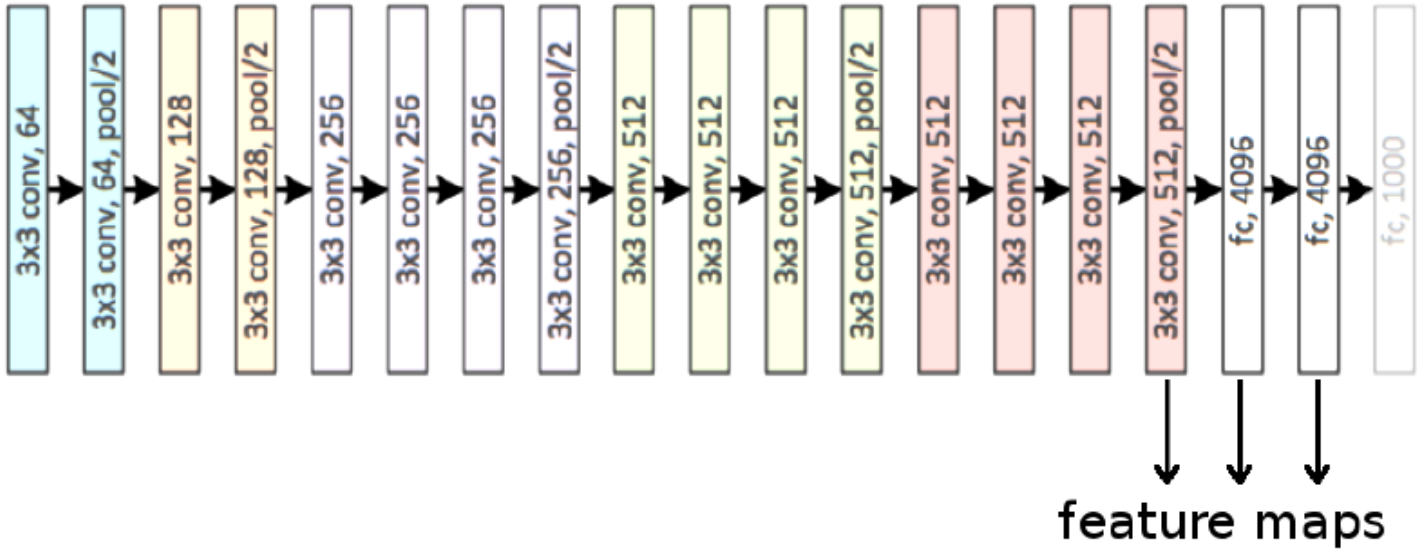

Agradecimentos

- Agradeço aos professores
  - Prof. Anderson Soares – Universidade Federal de Goiás (UFG)
  - Anderson Tenório - Universidade Federal de Pernambuco (UFPE)
  - Prof. Moacir Ponti - Universidade de São Paulo (USP)
  - Prof. Eduardo Bezerra (CEFET/RJ)
- pelo material disponibilizado